
机器心理学 (MACHINE PSYCHOLOGY)

Thilo Hagendorff* University of Stuttgart	Ishita Dasgupta* Google DeepMind	Marcel Binz† Helmholtz Institute for Human-Centered AI	Stephanie C.Y. Chan† Google DeepMind
Andrew Lampinen† Google DeepMind	Jane X. Wang† Google DeepMind	Zeynep Akata TU Munich	Eric Schulz Helmholtz Institute for Human-Centered AI

2026 年 8 月 19 日

ABSTRACT

大语言模型 (LLM) 展现出日益先进的涌现能力, 并被整合到各个社会领域之中。因此, 理解它们的行为与推理能力具有极其重要的意义。我们认为, 一个有前景的研究方向是让 LLM 参与受心理学启发的行为实验——这类实验传统上旨在理解人类的认知与行为。在本文中, 我们重点介绍并总结了这一研究路径所带来的理论视角、实验范式与计算分析技术。它为生成式人工智能 (AI) 的“机器心理学”铺平了道路: 这种研究超越了性能基准, 转而关注能够推动我们更好地理解与发现 LLM 中涌现能力和行为模式的计算洞见。我们回顾了采用这一路径的现有工作, 综合了最佳实践, 并指出了有前景的未来方向。同时, 我们也强调了将原本用于理解人类的方法论应用于机器时的重要注意事项。我们断言, 随着模型演变得更加强大、不透明、多模态, 并融入复杂的现实世界环境, 利用实验心理学工具来研究 AI 将变得愈发有价值。

引言

计算能力、数据可得性和机器学习算法的近期进展, 催生了几乎应用于社会各领域的强大人工智能系统。其中, 大语言模型 (LLM) ——在大量文本上训练的巨大神经网络架构——其影响力的上升尤为迅猛。LLM 直接以自然语言交互的能力, 使其以前所未有的方式为公众所使用, 带来了数百万日常用户的广泛采用 (Gemini Team et al., 2024; Anthropic, 2024; OpenAI, 2022; OpenAI, 2023a)。此外, LLM 影响力的上升还源于其任务类型的广泛性——从编写文本或代码, 到调用函数、访问互联网、检索外部信息、推理复杂问题, 不一而足 (Bubeck et al., 2023; Lo et al., 2022; Elkins and Chun, 2020)。近期, LLM 已被扩展到与其他模态交互, 例如视觉与语音 (Fei et al., 2022; Radford et al., 2023)。这些系统不断增长的能力

* Shared first authorship. Contact: thilo.hagendorff@iris.uni-stuttgart.de, idg@google.com

† Co-authors are listed in alphabetical order.

使其难以刻画，但也使刻画与理解它们变得日益重要，尤其是因为这些不断扩展的能力也带来了更大的不可预见危害的潜在可能 (Bommasani et al., 2021; Hagendorff, 2024b; Weidinger et al., 2022; Bender et al., 2021; Schramowski et al., 2022)。




图 1: 机器心理学关键概念概览。

理解 LLM 中的行为模式与涌现能力，需要解释其运行原理。在致力于解释 AI 系统的诸多方法中，许多依赖于尝试理解这些神经网络的内在运作机制。这种方法通常被称为机制可解释性 (mechanistic interpretability)，它通过分析 LLM 的权重与激活模式如何实现可观察行为来研究 LLM。它使用在数据、模型或两者层面上的简化，使因果干预成为可能，并让内部机制更易于刻画 (Stolfo et al., 2023; Conmy et al., 2023; Wang, Variengien, et al., 2022; Gao et al., 2024)。另一类相关方法更直接地从神经科学汲取灵感，以刻画 LLM 与人类在内部处理上的整体相关性异同 (Hosseini and Fedorenko, 2023; Kumar et al., 2022)。

与此相反，本综述聚焦于直接研究 LLM 行为的一类方法——分析输入与输出之间的关系，而非检视其内部运作。这类方法不仅包括对静态训练模型的分析，也包括在训练期间与训练之后对输入进行的实验性操控。它还涵盖了这样的输入与输出分析：即使不直接检视内部机制，也能揭示关于内部机制的洞见。对于这类方法，实验可以受到人类心理学、认知科学与行为科学的启发。这正是我们所说的机器心理学 (machine psychology) (参见图 1)。数十年来，上述学科已发展出广泛的方法与框架，用以理解和刻画人类及非人类动物可观察的智能行为 (Edwards, 1954; Festinger and Katz, 1953)，其中大部分如今也可以被适配到 LLM 上。

迄今为止，研究界已以多种方式回应了理解 LLM 行为模式与日益增长能力的挑战 (Schwartz, 2022; Zhao, Chen, et al., 2023)。传统的机器学习基准驱动路径发布了新的数据集，以捕捉模型中近期才涌现的特定能力 (Srivastava et al., 2022; Hendrycks et al., 2021; Zellers et al., 2019)。传统基准测试主要旨在让社区能够比较和优化 LLM 的性能。相比之下，机器心理学研究的主要兴趣不在于提高（或测量）LLM 的性能，而在于理解行为模式。虽然传统的自然语言处理基准测量的是翻译、数值推理或事实准确性等能力，但机器心理学同样关注这些可观察能力如何间接反映底层构念 (constructs) 与算法 (Frank et al., 2024)。理解这些构念使我们能够对模型将如何泛化、在不同训练数据下将如何表现，以及特定的失败模式等做出新的预测。

基于行为检视（即心理学）与基于内部检视（即神经科学）的相对重要性，是一场由来已久的辩论 (Jonas and Kording, 2017)。我们相信，这两种方法对于理解人类和 LLM 都有价值。然而，直接检视 LLM 的行为确实有多个优势。LLM 的行为在模型的接口层面表现出来，那里正是人类用户交互之处，因此也是

我们最终最关心的 (Binz and Schulz, 2023; Chang and Bergen, 2024; Ivanova, 2023)。这类行为往往过于复杂, 无法仅凭我们目前对模型权重与激活模式的机制性理解来预测 (Grön et al., 2003)。许多有趣的行为只由拥有数十亿参数的大型模型展现 (Kaplan et al., 2020; Wei, Tay, et al., 2022), 而心理学中将行为直接作为实验变量的行为学方法, 能够优雅地随模型规模扩展。另一个实际优势是, 这类行为方法可以很容易地被更广泛的学术界应用于不公开内部运作机制的闭源先进模型。

在本文中, 我们回顾并描绘了这一直接建模 LLM 行为的崭新领域的前进方向。我们概述了成熟的行为科学如何能够引导和启发我们对 LLM 的理解, 并讨论了将原本为人类与动物开发的方法应用于 LLM 时, 应何时以及如何应用的重要注意事项。在第一节中, 我们讨论心理学中发展出来用于组织我们对智能与智能行为理解的理论框架。随后, 我们回顾了许多为研究与刻画智能行为不同方面而开发的实证范式。最后, 我们讨论并提出稳健的实证方法建议, 既涉及实验设计, 也涉及行为数据分析。在文章结尾, 我们讨论以日益强大的黑盒模型开展机器心理学实验的潜力与局限。

理论: 理解智能系统的评估范式

机器学习算法的传统框架围绕基准数据集展开 (Bowman et al., 2015; Russakovsky et al., 2015)。这些数据集被设计为需要特定能力 (如物体识别、情感分析等) 才能获得良好性能。研究者在训练集上训练, 并在训练中未见过的留出测试集上评估。这一框架难以很好地推广到大规模基础模型, 原因有二。首先, 当使用互联网规模的数据训练模型时, 这种划分已变得难以维持 (Li and Flanigan, 2023; Khan et al., 2023)。其次, 基础模型只直接针对下一 token 预测进行训练, 却展现出许多其他可被视为涌现的“智能”行为 (尽管对此有所保留 (Schaeffer et al., 2023))。例如, 实践者并未明确编码或训练 transformer LLM 从上下文中少量示例学习的能力 (Brown et al., 2020), 但它仍然从机器学习架构、数据和学习信号中产生 (Chan et al., 2022; Oswald et al., 2023)。涌现行为难以通过产生它的组件视角来研究 (Anderson, 1972), 而且涌现出的行为可能令人惊讶 (Wei, Tay, et al., 2022)——最有趣的评估并非训练任务的“留出”样例。

因此, 研究者开始构建仅用于测试的基准——即规模较小、不适合训练、仅作为测试集的数据集——来研究模型能力, 例如包含 200 多项测试的 BIG-bench (Srivastava et al., 2022)、抽象与推理挑战 (Abstraction and Reasoning Challenge) (Chollet et al., 2020), 以及许多其他基准 (Ivanova et al., 2024; Mazumder et al., 2024)。在某些情况下, 这些基准已经类似于行为科学中的评估框架 (Bubeck et al., 2023)——比如应用于人类的性格测试、智力测试、内隐联想测试等——这些测试同样不遵循训练-测试范式。它们也往往分为两类: 一些评估侧重于标量性能指标, 如智商; 另一些则侧重于刻画行为, 即问题并非为追求准确率而设计, 而是旨在引发能够揭示行为策略或底层构念的回应。在本综述中, 我们聚焦于提供后一种理解的仅测试评估, 作为一种在机器学习领域开始获得关注的新的评估范式。

即使在预 LLM 时代, 也已经开发了若干此类诊断性评估——尽管模型是针对特定任务训练的, 但如何解决这些任务并未被规定。这类诊断数据集被用来揭示学习系统解决问题的方式——常常与人类的直觉相悖 (Geirhos et al., 2020; McCoy, Pavlick, et al., 2019; Hermann and Lampinen, 2020; Dasgupta et al., 2022; Singla and Feizi, 2021)。研究者还主张借鉴行为学 (ethology)——动物学中研究非人类动物行为的分支——来解释机器学习系统中的机器行为 (Rahwan et al., 2019)。然而, 在 LLM 时代, 不仅如何解决任务未被规定, 模型能力本身也既非直接可知, 也非有意设计的。此外, 由于 LLM 可以通过自然语言进行评估, 这可以增强或取代行为学中相对简单的方法。这导致了基于语言的诊断性评估的广泛采用, 使实践者更容易、更直观地开发相关测试。

然而，这伴随着重要的注意事项。在试图阐明一个能够产生语言的黑盒系统的工作机制时，人们很容易采用最简单的方法——直接询问系统本身。自我报告测量在心理学中也被广泛使用；但它们的可靠性在人类 (Jobe, 2003) 和 LLM 中都存疑。这类测量通常考虑的特性，如性格、道德或临床障碍，以对提示 (prompting) 敏感而闻名 (Dominguez-Olmedo et al., 2023; Röttger et al., 2024)；以至于最近的几项工作甚至用不同提示的 LLM 模拟不同社会群体、观点和性格的人类群体 (Salewski et al., 2023; Park et al., 2022; Argyle et al., 2023; Shanahan et al., 2023)。使用心理学中的自我报告刺激仍有价值——例如，刻画模型在默认提示下的行为，以及理解模型在这些维度上多大程度上可被引导（即对提示敏感）。但这些测量得出的结果应被情境化地看待（例如，作为特定系统提示下模型的属性），而不是作为 LLM 本身的根本性或一般性属性。

相比之下，心理学的实证传统与自我报告显著不同。这一传统产生了对自然智能的持久理解 (Frank et al., 2024)，也是我们认为最适合将洞见转移到机器心理学的传统。在这一范式中，外部观察到的行为仍然是测量的实验变量，但刺激的设计使不同的可观察行为映射并测量不同的内部表征、能力或构念——如组合性、心智理论、逻辑、因果性等。一个关键原则是实验由假设驱动：如果智能体拥有表征或构念 X，我们预期会看到行为 Y，否则会看到行为 Z。我们强调这一传统中在进行和解释机器心理学评估时必须牢记的两个关键原则。第一，看到行为 Y 是否可靠地意味着拥有构念 X？要回答这个问题，良好对照的设计至关重要——以确保行为 Y 没有其他解释，且确实蕴含 X。实验心理学很大一部分工作都在为这些微妙构念设计正确的对照 (Boring, 1954)，并为机器心理学的未来研究提供了宝贵的基础。第二，行为 Y 的缺失是否表明构念 X 的缺失？这是一个更微妙的问题。心理学研究经常面对这样一个事实：人类的表现可能嘈杂或有偏差；例如，人类即使在简单的计算上也可能犯错，或在口语中产生不合语法的表达。这些不应被视为他们缺乏数学或语言的抽象能力。这些不一致导致了表现-能力区分 (performance-competence distinction) 概念的产生 (e.g. Chomsky, 1965)：人类在特定情境下的表现方式可能无法完全反映其潜在的能力。最近的研究表明，类似的问题也适用于评估机器学习系统的能力 (Firestone, 2020)，尤其是 LLM (Lampinen, 2022)。

范式：智能行为的诸多方面

智能行为有许多方面，每个方面都由行为科学的不同子领域研究。每个子领域都发展出了特定领域的实证范式。虽然其中一些子领域（如运动学习）和范式（如瞳孔测量）因依赖于物理身体的存在而无法直接迁移到 LLM，但若干范式纯粹是语言性的，可以轻松迁移。随着 LLM 扩展其可解释刺激的种类——例如视觉 (OpenAI, 2023b; Zhang, Huang, et al., 2024; Gemini Team et al., 2024)——以及与世界交互的方式——例如具身和工具使用 (Mialon et al., 2023)——可迁移范式的空间也在增加。人类也通过与多种模态交互，而为理解我们而开发的范式常常比较并整合这些模态 (Schulze Buschoff et al., 2023)——例如横跨视觉与阅读能力的斯特鲁普 (Stroop) 测试 (Scarpina and Tagini, 2017)。

在本文中，我们聚焦于基于语言的测试，因为它们是当前研究格局中使用最广泛的。此外，我们相信，即使面对多模态模型的增长趋势，语言仍将保持其首要模态地位，因为它在模型的推理过程中扮演根本性角色。我们集中讨论四个可以为机器心理学研究的不同脉络提供信息的研究领域：启发式与偏差、社会互动、语言心理学与学习。当然，除这四个领域外，心理学中还有其他多个领域也可以提供有价值的范式，例如在研究 LLM 的创造力 (Stevenson et al., 2022)、临床心理学 (Li, Li, et al., 2022)、道德行为 (Khandelwal et al., 2024) 等方面。

启发式与偏差

启发式与偏差框架是心理学中最具影响力的研究范式之一 (Gigerenzer and Gaissmaier, 2011; Tversky and Kahneman, 1974)。启发式是简化推理或决策过程的心理捷径，这一领域研究这类捷径如何有助于解释人类行为中的成功与偏差。关于人类启发式与偏差的大量现有文献，是检视最新一代 LLM 中此类捷径的沃土——如今 LLM 的能力与这些文献所研究的人类能力有更多重叠。Binz and Schulz (2023) 是最早使用这一范式来更好地理解 LLM 决策过程的研究者之一。他们发现 GPT-3 (Brown et al., 2020) 展现出人们在身上观察到的一些相同认知偏差。还有若干其他工作也沿此脉络展开 (Jones and Steinhardt, 2022; Yax et al., 2024; Hagendorff et al., 2023; Macmillan-Scott and Musolesi, 2024; Schulze Buschoff et al., 2023; Hayes et al., 2024; Coda-Forno, Binz, Wang, et al., 2024)。有趣的是，多项研究的证据表明，虽然上一代模型经常表现出类似人类的启发式与偏差，但它们在最新一代 LLM 中已基本消失 (Chen, Liu, et al., 2023; Hagendorff et al., 2023)。测试刺激最初是为给人类研究参与者带来挑战而设计的，可能已不再能挑战 LLM 不断增长的推理能力。这也可能是训练集泄露所致——我们将在设计与分析一节讨论这一挑战。

关于启发式与偏差的文献还表明，问题的表述方式会影响人们如何解决它 (Cheng and Holyoak, 1985; Tversky and Kahneman, 1981)。众所周知，LLM 也容易受到类似操控的影响。例如，Dasgupta et al. (2022) 使用文献中的若干现有任务，研究了 LLM 是否受逻辑推理问题语义内容的影响。他们发现，与人类一样，LLM 对熟悉、可信或情境化的情境的推理比对不熟悉、不可信或抽象的问题更准确。同样，Schubert et al., 2024 表明，LLM 如何进行上下文学习取决于问题的表述形式。

最后，人们并非简单地应用任意的启发式。相反，他们使用的启发式适应于其在日常与世界互动中遇到的问题 (Todd and Gigerenzer, 2012)。就 LLM 而言，可以考察训练数据的属性如何塑造其行为。例如，Chan et al., 2022 证明，LLM 中上下文学习的存在可以追溯到数据分布属性，例如突发性 (burstiness)——项目以聚类形式出现而非随时间均匀分布——以及大量稀有类别类的存在。研究者还提出，应尝试通过 LLM 被训练去解决的问题来理解 LLM，就像行为科学家试图通过生态理性 (ecological rationality) 的视角理解人类认知一样 (Todd and Gigerenzer, 2012; McCoy, Yao, et al., 2023; Jagadish et al., 2024)。

社会互动

传统上，发展心理学探索人类在一生中如何在认知、社会与情感上发展。这包括研究影响发展的各种因素，如社会智力或社交技能。通过将发展心理学这一领域的范式应用于 LLM，研究者可以更深入地理解这些模型如何处理复杂的社会互动。特别是，一旦 LLM 作为聊天智能体部署，它们应当精通对人类沟通者的建模。因此，评估 LLM 的社会智力水平非常重要。此背景下的一例是将心智理论 (theory of mind) 测试应用于 LLM，研究者使用人类实验中的任务，例如 Wimmer and Perner (1983) 和 Perner et al. (1987) 的著名实验。虽然对 GPT-3 等模型的早期实验表明它们难以解决心智理论任务 (Sap et al., 2022)，但后来的模型展现出日益增强的、可靠推断他人不可观察心理状态的能力 (Strachan et al., 2024; Holterman and Deemter, 2023; Moghaddam and Honey, 2023)。进一步的相关研究考察 LLM 在心智理论测试上的表现与儿童相比如何 (Duijn et al., 2023)、LLM 处理需要关于多重心理状态递归推理的高阶心智理论任务的能力 (Street et al., 2024)，或衡量心智理论测试设置对 LLM 接收任务中干扰性改动的稳健性 (Ullman, 2023)。由于心智理论测试除其他外还测量理解错误信念的能力，进一步的研究探索了 LLM 在其他智能体中诱导错误信念的涌现能力 (Hagendorff, 2024a)，或 LLM 如何在诚实、助人等不同沟通价值之间权

衡 (Liu et al., 2024)——这些研究也有助于理解和改善与人类价值观的对齐, 以服务于 AI 安全 (Ji et al., 2023)。

随着 LLM 被允许通过自我反思 (Nair et al., 2023)、自我指令 (Wang, Wei, et al., 2022) 或以群体 (swarm) 形式交互, 相关范式的空间也在增加。例如, 研究者考察了 LLM 在游戏中合作与协调的行为, 揭示了模型中持久的行为特征 (Akata et al., 2023)。类似地, 研究者在受心理学启发的困境情境中调查 LLM 的合作或竞争行为, 以评估 LLM 参与现实世界谈判的能力 (Phelps and Russell, 2024)。另一项受人类社会心理学工作影响的研究, 考察了多个 LLM 如何形成并演化网络, 研究优先连接 (preferential attachment) 或三角闭合 (triadic closure) 等微观网络原则, 以及社区结构等宏观原则 (Papachristou and Yuan, 2024)。总之, 机器心理学可以揭示 LLM 之间个体与集体的社会行为与互动模式, 无论是用于问题解决还是世界模拟 (Guo et al., 2024)。通过借鉴人类发展心理学与社会动力学, 研究者可以更好地理解和设计能够在复杂社会互动中游刃有余并展现高级社交技能的 LLM。

语言心理学

关于人类如何使用和理解语言的心理学长期研究史, 涵盖从人们如何利用语义和句法特征来理解句子, 到如何在话语语境中利用语用推理来帮助解读他人所言。相应地, 也有长期的工作研究语言处理模型如何捕捉人类语言处理的这些特征。早期联结主义工作研究简单循环预测模型中的这些主题 (Elman, 1991; McClelland et al., 1989); 最近, 研究者将类似技术应用于研究 LLM。大量工作研究了模型学习了哪些句法知识 (Linzen and Baroni, 2021), 通常使用心理语言学的方法。例如, Wilcox et al. (2023) 使用受心理语言学启发的惊奇度 (surprisal) 测量, 表明 LLM 学会了填充语-空位依存关系 (filler-gap dependencies), 这是一种具有挑战性的句法结构。其他研究者使用相关测量来研究 LLM 学到了什么关于蕴涵语义的知识 (Merrill et al., 2024)。此外, 研究者使用启动效应 (priming) 等心理语言学技术来研究模型如何表征和处理语言 (Prasad et al., 2019; Sinclair et al., 2022), 并使用去混杂刺激等方法识别模型可能在何处依赖语义启发式而非句法 (McCoy, Pavlick, et al., 2019)。最近几项工作 (Hu, Floyd, et al., 2023; Ruis, Khan, et al., 2023) 研究了 LLM 的语用判断, 发现较大的模型以及经过指令微调的模型倾向于更好地接近人类反应与错误模式——尽管仍存在一些不足。在另一项研究中, 研究者检视了 ChatGPT 生成的长篇类比, 发现 AI 生成的类比缺乏某些类似人类的心理语言学特性 (Seals and Shalin, 2023), 尤其是在文本连贯性、语言和可读性方面。此外, 研究者将花园路径句 (garden path sentences) ——因结构歧义而引导读者最初误解的句子——应用于 LLM, 表明模型的反应与人类相似 (Aher et al., 2023; Christianson et al., 2001)。在更高层面上, 一些研究者从人类语言发展的某些方面汲取灵感, 试图识别语言模型相对数据低效的原因 (Warstadt et al., 2023; Frank, 2023)。在以上每种情况下, 心理学和心理语言学的方法与思想都为如何通过 LLM 的语言行为评估其过程提供了指导, 可能的方式是在 LLM 与人类之间进行比较。

学习

学习心理学关注个体如何获取和保持知识与技能。乍一看, 研究学习的实验范式似乎不太适用于 LLM, 因为行为实验的目的往往在于帮助揭示底层学习算法——而对 LLM 而言, 训练中使用的学习算法是设计好的且已知的。然而, 在此背景下行为科学仍能从对 LLM 的研究中获益, 因为 LLM 展现出并未被明确设计进模型的学习能力 (它们是涌现的), 因此人们并不理解其底层学习算法。特别是, LLM 展现出涌现的上下文学习 (in-context learning) ——无需任何基于梯度的权重更新, 即可从上下文 (提示)

中学习的能力 (Brown et al., 2020)。理解上下文学习是一个蓬勃发展且重要性迅速提升的领域，这得益于 LLM 上下文窗口的不断增大及随之而来的能力增长，例如仅从上下文中学习一门完整语言的能力 (Munkhdalai et al., 2024; Gemini Team et al., 2024)，或克服安全微调的能力 (Anil et al., 2024; Zheng et al., 2024)。

揭示上下文学习所实现的隐式学习算法是一个蓬勃发展的研究领域，它利用了认知科学中许多常见方法。例如，多项研究将 transformer 上下文学习的输出与假设学习算法的输出进行比较 (Oswald et al., 2023; Akyürek et al., 2022)。这是认知建模的常用手段，并且可能进一步受益于心理学与统计学中的模型比较程序 (Yang, 2006; Arlot and Celisse, 2010; Vrieze, 2012)。认知科学中的近期工作已使用机器学习来发现人类决策的新理论 (Peterson et al., 2021)——将相关方法应用于上下文学习也可能很有意思。研究者还可能受益于将特定模型视为规范性起点 (Niv, 2009)。

研究者可能还想理解学习的其他有趣而重要的特征，如归纳偏差与泛化、学习对数据的依赖性，以及学习随时间变化的动态。这些特征即使在已知学习算法的情况下也常常不明显，因此研究者不仅希望理解上下文学习中的这些特征，也希望理解 LLM 学习的其他形式，例如基于梯度的自监督学习、强化学习 (Ouyang et al., 2022)，或“快速”记忆检索 (Borgeaud et al., 2022; Lewis et al., 2020)。

为了刻画 LLM 的归纳偏差与泛化，研究者从认知科学 (Schubert et al., 2024; Coda-Forno, Binz, Akata, et al., 2023) 和贝叶斯推断 (Xie et al., 2022) 中借鉴了概念与实验范式。研究利用测量系统性泛化的范式来刻画 LLM 的这些能力，并将其作为改进这些能力的灵感 (Lake and Baroni, 2023; Ruis, Andreas, et al., 2022)。Webb et al. (2023) 创造了认知科学中经典类比问题的新变体，以考察大语言模型的类比能力。Chan et al. (2022) 借鉴了关于“基于规则”与“基于示例”泛化的思想与实验范式，以刻画 transformer 中权重内学习与上下文学习的归纳偏差。此外，研究者从发展心理学中借鉴范式与测量，以刻画 LLM 的归纳偏差可能在哪些领域与儿童一致、在哪些领域有所不足（包括因果推理与创新）(Kosoy et al., 2023; Yiu et al., 2023)。

为了刻画上下文学习对数据的依赖性，现有工作从发展心理学关于偏斜分布和突发分布的研究中汲取了灵感 (Chan et al., 2022)。数据依赖的一个重要方面是数据随时间（训练期间）的结构。AI 研究者长期从人类与非人类动物的课程学习 (curriculum learning) 中汲取灵感，以更好地理解如何组织训练数据，使先学习较容易的任务能够为后学习较困难的任务搭建脚手架 (Bengio et al., 2009)。关于学习的行为研究中，仍有许多领域可以作为数据依赖的丰富灵感来源，例如关于重复与间隔的研究 (Dempster, 1989)、工作记忆 (Baddeley, 2010; Chai et al., 2018)、分块 (blocking) 与交错 (interleaving) 任务 (Carvalho and Goldstone, 2015)，以及持续学习 (Greco et al., 2019)。数据依赖对 LLM 而言尤其有趣，因为文本训练数据（主要来自非结构化的网络规模语料库）与传统的判别式机器学习技术通常使用的结构化训练数据截然不同，而且数据是训练 LLM 时可用于调整其行为的主要杠杆之一。

设计与分析：良好的行为实验

计算机科学在历史上并非一门实证科学。虽然机器学习（尤其是自神经网络模型时代以来）在很大程度上由实证而非理论工作驱动，但这些规程得以发展的条件——对所有实践者固定且实际上无限大的测试集——在小型、仅测试的行为实验场景中已不再成立。当前的 LLM 以对提示结构的微小变化敏感而闻名，或依赖浅层的句法启发式 (McCoy, Pavlick, et al., 2019)，不谨慎检验其结论稳健性的研究有产

生虚假且不可泛化结果的风险。心理学也有过自己的可复现性危机 (Open Science Collaboration, 2015; Haibe-Kains et al., 2020), 机器心理学不应重蹈覆辙。在本节中, 我们为使用 LLM 的行为测试场景提供可靠方法学的建议, 这对机器心理学领域的实践者应有价值。

提示方法与偏差

机器心理学领域的许多研究有一个共同的重大缺陷, 即它们没有避免训练数据污染。它们使用现有心理学研究中的提示, 并在不改变措辞、任务顺序等的情况下将其应用于 LLM。这样一来, LLM 很可能在训练中已经遇到过相同或相似的任务, 从而只是简单地复现已知的 token 模式。在采用心理学中的测试框架时——即情境短文 (vignettes)、认知任务或其他测试设置——研究者必须确保 LLM 从未见过这些测试, 并超越单纯的记忆。因此, 提示在结构上确实可以与现有任务相似, 但应包含新的措辞、主体、顺序、动作等。话虽如此, 一些实验可以是程序化生成的 (而非由静态数据集组成), 这使得它们从本质上不那么容易受到数据污染问题的影响 (Coda-Forno, Binz, Wang, et al., 2024)。

现有若干机器心理学研究的另一个常见缺陷是依赖小样本量或便利样本, 即非系统化的提示序列。所用基准或任务数据集中的抽样偏差——在小样本量中尤为普遍——会降低机器心理学研究的质量。这是因为提示的细微变化可能显著改变模型输出。鉴于这种对提示措辞的高度敏感性, 测试同一任务的多个版本并创建有代表性的样本 (即多样化的提示组) 非常重要。只有这样, 才能可靠地衡量某种行为是否系统地重复出现并可泛化 (Yarkoni, 2022)。此外, LLM 可能屈服于影响提示处理的各种偏差 (Zhao, Wallace, et al., 2021; Chan et al., 2022)。例如, LLM 中的近因偏差 (recency bias) 导致其更倾向于依赖出现在提示末尾的信息。LLM 还可能具有常见 token 偏差, 即模型偏向于输出其训练数据中常见的 token。此外, 多数标签偏差 (majority label bias) 可能导致 LLM 偏向少样本学习场景中频繁出现的标签、类别或示例。在设计提示或提示变体时, 至少可以在一定程度上控制这类技术偏差, 使其倾向于避免触发这些偏差。如果不这样做, LLM 可能依赖利用此类偏差的捷径。

用提示引出能力

标准提示设计 (由情境短文加上开放式或封闭式问题或任务组成) 可以通过引出 LLM 增强推理能力的前缀或后缀来改进。另一方面, 省略此类前缀和后缀可能导致对模型能力的低估。虽然大多数特定的提示增强可能只对某类任务有积极影响而对其他任务无益, 从而削弱我们系统理解 LLM 行为的能力, 但已有少数提示设计方法被发现能带来更广泛的性能收益。最值得注意的是, (零样本) 思维链提示 (Wei, Wang, et al., 2022; Kojima et al., 2022)——即在提示末尾简单地加上“让我们一步一步地思考” (Let’s think step by step)——能够提升推理表现。这甚至可以进一步扩展: 生成多条思维链推理路径, 并取多数响应作为最终答案 (Wang, Wei, et al., 2022)。与思维链提示类似的是由简到繁提示 (least-to-most prompting), 它同样将问题分解为一组子问题以提高 LLM 的准确率 (Zhou et al., 2022)。另一种方法是以多项选择格式组织问题。已有研究表明, 这在某些情况下能提升推理能力 (Kadavath et al., 2022), 但也可能限制推理, 因为 LLM 可能被引导给出简短回答, 从而在提示补全过程中绕过推理。尽管如此, 许多著名的 NLP 基准使用多项选择格式而非开放式问题。在此, 必须牢记同一概念的不同表述会在概率上相互竞争, 这可能降低选出正确答案的几率 (Holtzman et al., 2021)。此外, 还必须考虑潜在的近因偏差, 这需要通过多次测试运行中打乱答案顺序来中和该效应, 以覆盖所有可能的组合。另一种增强推理的方法是利用 LLM 的少样本学习能力 (Brown et al., 2020), 即 LLM 在反复接触给定任务后表现会提升。此外, 自我

反思——即 LLM 对其输出进行自动的、递归的批评并随后自我改进——是另一种可以提升推理能力的技术 (Nair et al., 2023; Kim et al., 2023)。在符号或数值推理的改进方面，另一种技术是提示 LLM 使用代码来解决问题 (Zhang, Ge, et al., 2024)。最终，所有提到的提升推理的方法不仅可用于机器心理学，它们本身也可以成为研究对象。

设置参数与评估输出

LLM 带有研究者可以设置的多种参数。例如，大多数模型有多种规模可供选择。跨规模的比较分析很有价值：虽然最大的模型通常能力最高，但一些近期工作发现了“逆缩放” (inverse-scaling) 现象 (McKenzie et al., 2023)。此外，温度设置控制随机性。如果需要精确的可复现性，研究应使用温度 0 或指定随机种子以确保完全确定性。然而，这容易受到（有意或无意的）种子选择偏差的影响。温度对能力的影响尚未确定 (Renze and Guven, 2024)，而报告平均值或“最佳 K” (best of K) ——即考虑 K 次采样中满足某些简单标准（如格式 (Chen, Tworek, et al., 2021)）的所有响应——是有价值的。

在开展实验之后，必须评估 LLM 响应列表并与真实值 (ground truth) 进行比较。最简单的情况是结果可以按多项选择题的形式组织和评分——不过即使在这种情况下，让模型直接内联作答（而非选择选项）的评分方式也能带来更多信号 (Hu and Levy, 2023)。如果可能，应比较多种评分方法，以评估效应是否依赖于评分方法 (Tsvilodub et al., 2024)。如果问题必须以自由生成的方式回答，那么当结果表现出足够的简单性和规律性时，评估过程仍然可以自动化，即 LLM 响应在长度和措辞上与真实值字符串相似，这在掩码语言模型中尤为常见。可以使用正则表达式测试单词重叠等的方法，或采用 F1 分数等指标。然而，最先进的 LLM 往往产生高度多变且全面的输出，这会使分类复杂化。虽然停止序列、token 限制或中断进一步文本生成的提示指令可以通过促进输出的一致性来方便分类，但它们也以不当方式约束了 LLM 行为。因此，研究者日益依赖基于 LLM 的输出评估，即由单个模型或多个堆叠的模型实例使用精心设计的指令执行分类。尽管这种方法对于非常全面的输出可能仍不准确，但一个解决方案是指示被审查的 LLM 在特定的字符串序列（如“####”）之后输出其最终答案或摘要 (Cobbe et al., 2021)。这种方法允许 LLM 在冗长的提示补全过程中进行推理，而这对思维链推理等许多提示工程技术来说是必要的。分类随后只需处理“####”之后的字符串。如果这种方法仍不可靠，则可能必须手动进行评估，或许需要雇佣研究助理或承包商。评估之后，可以进行统计分析。

讨论

机器心理学提供了一种解释 AI 的新方法。与其解读神经网络的各设计组件 (Barredo Arrieta et al., 2019)，不如分析输入与输出之间的关系，即提示设计与提示补全。虽然这可能有助于识别 LLM 中迄今未知的能力或行为特征，但解读 LLM 响应也伴随着挑战。存在一种强烈的倾向，即将迄今只保留给人类和动物心智的心理概念或术语赋予 LLM。这种倾向体现在“机器学习”等常见术语中，但地图推理 (Huang and Chang, 2022)、直觉 (Hagendorff et al., 2023)、创造力 (Stevenson et al., 2022)、智力 (Webb et al., 2023)、人格 (Miotto et al., 2022)、精神疾病 (Li, Li, et al., 2022) 等概念被迁移到 LLM 时，这种倾向在机器心理学中将变得更加普遍。在此背景下，研究者呼吁谨慎，强调这些概念背后的神经机制在人类与机器中是不同的 (Shanahan, 2022; Mahowald et al., 2024)。此外，许多心理概念带有规范性负荷，可能助长 AI 专家与公众在机器能力期望上的错位 (Shevlin and Halina, 2019)。然而，LLM 中的许多能力无法仅通过参考其神经架构的内在运作来合理把握，这一问题依然存在。

借用民族志 (ethnography) 的一个概念, 可以将这种进路称为“薄描述” (thin descriptions) (Ryle, 1971; Geertz, 1973), 即只解释 AI 系统中的内部表征, 例如通过激活图谱 (activation atlases) ——它将神经网络的不同部分如何响应各种输入可视化 (Carter et al., 2019)。在这个意义上, LLM 只是通过使用心理学或其他人类中心术语“劫持”了人类的直觉, 以解释机器行为模式。然而, 与薄描述相反, 还有“厚描述” (thick descriptions)。它们意味着使用心理学术语来增加一层可解释性。LLM 与人类大脑一样, 在某种程度上是黑盒。即使这些术语没有直接对应的神经相关物, 将心理学术语应用于它们也能增加解释力。这对人类同样成立: 用于解释行为的心理术语并不直接与特定的神经激活集相关。通过设定 (心理的) 不可观察状态——无论是关于大脑还是人工神经网络——人们增加了解释资源 (Sellars, 1997)。当薄描述不足以解释行为模式时, 厚描述有助于理解 LLM。薄描述假设 LLM 仅拥有句法或关联词汇的统计能力 (Searle, 1980; Floridi and Chiriatti, 2020; Bender et al., 2021), 但不拥有语义。而厚描述假设 LLM 展现出超越纯粹句法的模式与规律。这些模式可以通过机器心理学来解释。

除了在机器语境下借用心理学术语的潜在习惯化问题之外, 机器心理学作为一个新兴研究领域, 旨在通过将 LLM 视为心理学实验的参与者, 来识别其行为模式、涌现能力以及决策和推理机制。当考虑多模态或增强型 LLM——即被允许与图像、外部信息来源、感官数据、物理对象以及各种其他工具交互的 LLM——时, 这一评估 LLM 的新学科将变得更加重要 (Mialon et al., 2023; Schick et al., 2023; Ma et al., 2024)。此外, 一旦机器心理学的测试设置得以建立, 研究者可以通过多次应用相同任务来研究 LLM 如何随时间发展, 从而获得纵向数据。这些数据可以作为外推 LLM 推理能力发展趋势的基线。此类估计对 AI 安全和 AI 对齐研究预测 LLM 未来行为潜力可能日益重要。通过更深入地理解这些潜力, 机器心理学正在为 AI 可解释性提供一种新方法, 也是对自然语言处理中传统基准测试方法的重要补充。

作者贡献

TH 和 ID 构思并领导了手稿的初始设计。TH 和 ID 撰写了初稿, MB、SCYC、AL、JW、ZA 和 ES 参与充实各章节并创建了插图。所有作者都参与了反复修改, 并编辑和审阅了论文。

References

- Aher, Gati, Rosa I. Arriaga, and Adam Tauman Kalai. “Using Large Language Models to Simulate Multiple Humans and Replicate Human Subject Studies”. In: *Proceedings of the 40th International Conference on Machine Learning*. 2023, pp. 1–35.
- Akata, Elif, Lion Schulz, Julian Coda-Forno, Seong Joon Oh, Matthias Bethge, and Eric Schulz. “Playing repeated games with Large Language Models”. In: *arXiv* (2023), pp. 1–13.
- Akyürek, Ekin, Dale Schuurmans, Jacob Andreas, Tengyu Ma, and Denny Zhou. “What learning algorithm is in-context learning? Investigations with linear models”. In: *arXiv* (2022), pp. 1–29.
- Anderson, Philip W. “More is different: Broken symmetry and the nature of the hierarchical structure of science”. In: *Science* 177.4047 (1972), pp. 393–396.
- Anil, Cem et al. *Many-shot jailbreaking*. 2024.
- Anthropic. *The Claude 3 Model Family: Opus, Sonnet, Haiku*. 2024.

- Argyle, Lisa P, Ethan C Busby, Nancy Fulda, Joshua R Gubler, Christopher Rytting, and David Wingate. “Out of One, Many: Using Language Models to Simulate Human Samples”. In: *Political Analysis* 31.3 (2023), pp. 337–351.
- Arlot, Sylvain and Alain Celisse. “A survey of cross-validation procedures for model selection”. In: *Statistics Surveys* 4 (2010), pp. 40–79.
- Baddeley, Alan. “Working memory”. In: *Current Biology* 20.4 (2010), R136–R140.
- Barredo Arrieta, Alejandro et al. “Explainable Artificial Intelligence (XAI): Concepts, Taxonomies, Opportunities and Challenges toward Responsible AI”. In: *Information Fusion* 58 (2019), pp. 82–115.
- Bender, Emily M, Timnit Gebru, Angelina McMillan-Major, and Shmargaret Shmitchell. “On the Dangers of Stochastic Parrots: Can Language Models Be Too Big?” In: *Proceedings of the 2021 ACM conference on fairness, accountability, and transparency*. 2021, pp. 610–623.
- Bengio, Yoshua, Jérôme Louradour, Ronan Collobert, and Jason Weston. “Curriculum learning”. In: *Proceedings of the 26th Annual International Conference on Machine Learning*. 2009, pp. 41–48.
- Binz, Marcel and Eric Schulz. “Using cognitive psychology to understand GPT-3”. In: *Proceedings of the National Academy of Sciences* 120.6 (2023), pp. 1–10.
- Bommasani, Rishi et al. “On the opportunities and risks of foundation models”. In: *arXiv* (2021), pp. 1–214.
- Borgeaud, Sebastian, Arthur Mensch, Jordan Homann, Trevor Cai, Eliza Rutherford, and Katie Millican. “Improving Language Models by Retrieving from Trillions of Tokens”. In: *Proceedings of the 39th International Conference on Machine Learning*. Ed. by Kamalika Chaudhuri, Stefanie Jegelka, Le Song, Csaba Szepesvari, Gang Niu, and Sivan Sabato. Vol. 162. 2022, pp. 2206–2240.
- Boring, Edwin G. “The Nature and History of Experimental Control”. In: *The American Journal of Psychology* 67.4 (1954), pp. 573–589.
- Bowman, Samuel R., Gabor Angeli, Christopher Potts, and Christopher D. Manning. “A large annotated corpus for learning natural language inference”. In: *Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing*. Ed. by Lluís Màrquez, Chris Callison-Burch, and Jian Su. 2015, pp. 632–642.
- Brown, Tom et al. “Language Models are Few-Shot Learners”. In: *Advances in Neural Information Processing Systems*. Ed. by H. Larochelle, M. Ranzato, R. Hadsell, M.F. Balcan, and H. Lin. Vol. 33. Curran Associates, Inc., 2020, pp. 1877–1901.
- Bubeck, Sébastien et al. “Sparks of Artificial General Intelligence: Early experiments with GPT-4”. In: *arXiv* (2023), pp. 1–155.
- Carter, Shan, Zan Armstrong, Ludwig Schubert, Ian Johnson, and Chris Olah. “Exploring Neural Networks with Activation Atlases”. In: *Distill* 4.3 (2019).
- Carvalho, Paulo F. and Robert L. Goldstone. “The benefits of interleaved and blocked study: different tasks benefit from different schedules of study”. In: *Psychonomic Bulletin & Review* 22.1 (2015), pp. 281–288.
- Chai, Wen Jia, Aini Ismafairus Abd Hamid, and Jafri Malin Abdullah. “Working Memory From the Psychological and Neurosciences Perspectives: A Review”. In: *Frontiers in Psychology* 9 (2018), pp. 1–16.
- Chan, Stephanie, Adam Santoro, Andrew Lampinen, Jane Wang, Aaditya Singh, Pierre Richemond, James McClelland, and Felix Hill. “Data Distributional Properties Drive Emergent In-Context Learning in Transformers”. In: *Advances in Neural Information Processing Systems* 35 (2022), pp. 18878–18891.

- Chang, Tyler A and Benjamin K Bergen. “Language Model Behavior: A Comprehensive Survey”. In: *Computational Linguistics* 50.1 (2024), pp. 293–350.
- Chen, Mark, Jerry Tworek, et al. “Evaluating Large Language Models Trained on Code”. In: *arXiv* (2021), pp. 1–35.
- Chen, Yiting, Tracy Xiao Liu, You Shan, and Songfa Zhong. “The emergence of economic rationality of GPT”. In: *Proceedings of the National Academy of Sciences* 120.51 (2023), e2316205120.
- Cheng, Patricia W and Keith J Holyoak. “Pragmatic reasoning schemas”. In: *Cognitive Psychology* 17.4 (1985), pp. 391–416.
- Chollet, François, Katherine Tong, Walter Reade, and Julia Elliott. *Abstraction and Reasoning Challenge*. 2020. URL: <https://kaggle.com/competitions/abstraction-and-reasoning-challenge>.
- Chomsky, Noam. *Aspects of the Theory of Syntax*. MIT Press, 1965.
- Christianson, Kiel, Andrew Hollingworth, John F. Halliwell, and Fernanda Ferreira. “Thematic Roles Assigned along the Garden Path Linger”. In: *Cognitive Psychology* 42.4 (2001), pp. 368–407.
- Cobbe, Karl et al. “Training Verifiers to Solve Math Word Problems”. In: *arXiv* (2021), pp. 1–22.
- Coda-Forno, Julian, Marcel Binz, Zeynep Akata, Matt Botvinick, Jane Wang, and Eric Schulz. “Meta-in-context learning in large language models”. In: *Advances in Neural Information Processing Systems* 36 (2023), pp. 65189–65201.
- Coda-Forno, Julian, Marcel Binz, Jane X Wang, and Eric Schulz. “CogBench: a large language model walks into a psychology lab”. In: *arXiv* (2024), pp. 1–26.
- Conmy, Arthur, Augustine N. Mavor-Parker, Aengus Lynch, Stefan Heimersheim, and Adrià Garriga-Alonso. “Towards Automated Circuit Discovery for Mechanistic Interpretability”. In: *Advances in Neural Information Processing Systems*. Ed. by A. Oh, T. Naumann, A. Globerson, K. Saenko, M. Hardt, and S. Levine. Vol. 36. Curran Associates, Inc., 2023, pp. 16318–16352.
- Dasgupta, Ishita, Andrew K. Lampinen, Stephanie C. Y. Chan, Antonia Creswell, Dharshan Kumaran, James L. McClelland, and Felix Hill. “Language models show human-like content effects on reasoning”. In: *arXiv* (2022), pp. 1–36.
- Dempster, Frank N. “Spacing effects and their implications for theory and practice”. In: *Educational Psychology Review* 1.4 (1989), pp. 309–330.
- Dominguez-Olmedo, Ricardo, Moritz Hardt, and Celestine Mandler-Dünner. “Questioning the Survey Responses of Large Language Models”. In: *arXiv* (2023), pp. 1–25.
- Duijn, Max J. van, Bram van Dijk, Tom Kouwenhoven, Werner de Valk, Marco R. Spruit, and Peter van der Putten. “Theory of Mind in Large Language Models: Examining Performance of 11 State-of-the-Art models vs. Children Aged 7-10 on Advanced Tests”. In: *Proceedings of the 27th Conference on Computational Natural Language Learning (CoNLL)*. Ed. by Jing Jiang, David Reitter, and Shumin Deng. 2023, pp. 389–402.
- Edwards, Allen L. *Statistical Methods for the Behavioral Sciences*. Rinehart, 1954.
- Elkins, Katherine and Jon Chun. “Can GPT-3 Pass a Writer’s Turing Test?” In: *Journal of Cultural Analytics* 5.2 (2020), pp. 1–16.
- Elman, Jeffrey L. “Distributed representations, simple recurrent networks, and grammatical structure”. In: *Machine Learning* 7 (1991), pp. 195–225.

- Fei, Nanyi et al. “Towards artificial general intelligence via a multimodal foundation model”. In: *Nature Communications* 13.1 (2022), pp. 1–13.
- Festinger, Leon Ed and Daniel Ed Katz. *Research methods in the behavioral sciences*. Holt, Rinehart and Winston, 1953.
- Firestone, Chaz. “Performance vs. competence in human–machine comparisons”. In: *Proceedings of the National Academy of Sciences* 117.43 (2020), pp. 26562–26571.
- Floridi, Luciano and Massimo Chiriatti. “GPT-3: Its Nature, Scope, Limits, and Consequences”. In: *Minds and Machines* 30.4 (2020), pp. 681–694.
- Frank, Michael C. “Bridging the data gap between children and large language models”. In: *Trends in Cognitive Sciences* 27.11 (2023), pp. 990–992.
- Frank, Michael C., Mika Braginsky, Julie Cachia, Nicholas Coles, Tom E. Hardwicke, Robert D. Hawkins, Maya B. Mathur, and Rondeline Williams. *Experimentology: An Open Science Approach to Experimental Psychology Methods*. MIT Press, 2024.
- Gao, Leo, Tom Dupré la Tour, Henk Tillman, Gabriel Goh, Rajan Troll, Alec Radford, Ilya Sutskever, Jan Leike, and Jeffrey Wu. “Scaling and evaluating sparse autoencoders”. In: *arXiv* (2024), pp. 1–34.
- Geertz, Clifford. *The Interpretation of Cultures: Selected Essays*. Basic Books, 1973.
- Geirhos, Robert, Jörn-Henrik Jacobsen, Claudio Michaelis, Richard Zemel, Wieland Brendel, Matthias Bethge, and Felix A. Wichmann. “Shortcut learning in deep neural networks”. In: *Nature Machine Intelligence* 2 (2020), pp. 665–673.
- Gemini Team et al. “Gemini 1.5: Unlocking multimodal understanding across millions of tokens of context”. In: *arXiv* (2024), pp. 1–90.
- Gigerenzer, Gerd and Wolfgang Gaissmaier. “Heuristic decision making”. In: *Annual Review of Psychology* 62 (2011), pp. 451–482.
- Greco, Claudio, Barbara Plank, Raquel Fernández, and Raffaella Bernardi. “Psycholinguistics Meets Continual Learning: Measuring Catastrophic Forgetting in Visual Question Answering”. In: *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*. Ed. by Anna Korhonen, David Traum, and Lluís Màrquez. Florence, Italy: Association for Computational Linguistics, 2019, pp. 3601–3605.
- Grön, Georg, David Schul, Volker Bretschneider, AP Wunderlich, and Matthias W Riepe. “Alike performance during nonverbal episodic learning from diversely imprinted neural networks”. In: *European Journal of Neuroscience* 18.11 (2003), pp. 3112–3120.
- Guo, Taicheng, Xiuying Chen, Yaqi Wang, Ruidi Chang, Shichao Pei, Nitesh V. Chawla, Olaf Wiest, and Xiangliang Zhang. “Large Language Model based Multi-Agents: A Survey of Progress and Challenges”. In: *arXiv* (2024), pp. 1–15.
- Hagendorff, Thilo. “Deception abilities emerged in large language models”. In: *Proceedings of the National Academy of Sciences* 121.24 (2024), pp. 1–8.
- “Mapping the Ethics of Generative AI: A Comprehensive Scoping Review”. In: *arXiv* (2024), pp. 1–25.
- Hagendorff, Thilo, Sarah Fabi, and Michal Kosinski. “Human-like intuitive behavior and reasoning biases emerged in large language models but disappeared in ChatGPT”. In: *Nature Computational Science* 3.10 (2023), pp. 833–838.

- Haibe-Kains, Benjamin et al. “Transparency and reproducibility in artificial intelligence”. In: *Nature* 586.7829 (2020), pp. 1–7.
- Hayes, William M, Nicolas Yax, and Stefano Palminteri. “Relative Value Biases in Large Language Models”. In: *arXiv* (2024), pp. 1–7.
- Hendrycks, Dan, Collin Burns, Saurav Kadavath, Akul Arora, Steven Basart, Eric Tang, Dawn Xiaodong Song, and Jacob Steinhardt. “Measuring Mathematical Problem Solving With the MATH Dataset”. In: *Thirty-fifth Conference on Neural Information Processing Systems*. 2021, pp. 1–11.
- Hermann, Katherine and Andrew Lampinen. “What shapes feature representations? Exploring datasets, architectures, and training”. In: *34th Conference on Neural Information Processing Systems*. 2020, pp. 1–12.
- Holterman, Bart and Kees van Deemter. “Does ChatGPT have Theory of Mind?” In: *arXiv* (2023), pp. 1–15.
- Holtzman, Ari, Peter West, Vered Shwartz, Yejin Choi, and Luke Zettlemoyer. “Surface Form Competition: Why the Highest Probability Answer Isn’t Always Right”. In: *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*. Ed. by Marie-Francine Moens, Xuanjing Huang, Lucia Specia, and Scott Wen-tau Yih. 2021, pp. 7038–7051.
- Hosseini, Eghbal A and Evelina Fedorenko. “Large language models implicitly learn to straighten neural sentence trajectories to construct a predictive representation of natural language”. In: *Advances in Neural Information Processing Systems*. Ed. by A. Oh, T. Naumann, A. Globerson, K. Saenko, M. Hardt, and S. Levine. Vol. 36. 2023, pp. 43918–43930.
- Hu, Jennifer, Sammy Floyd, Olessia Jouravlev, Evelina Fedorenko, and Edward Gibson. “A fine-grained comparison of pragmatic language understanding in humans and language models”. In: *The 61st Annual Meeting Of The Association For Computational Linguistics*. 2023, pp. 4194–4213.
- Hu, Jennifer and Roger P Levy. “Prompting is not a substitute for probability measurements in large language models”. In: *The 2023 Conference on Empirical Methods in Natural Language Processing*. 2023, pp. 5040–5060.
- Huang, Jie and Kevin Chen-Chuan Chang. “Towards Reasoning in Large Language Models: A Survey”. In: *arXiv* (2022), pp. 1–14.
- Ivanova, Anna A. “Running cognitive evaluations on large language models: The do’s and the don’ts”. In: *arXiv* (2023), pp. 1–12.
- Ivanova, Anna A et al. “Elements of World Knowledge (EWOK): A cognition-inspired framework for evaluating basic world knowledge in language models”. In: *arXiv* (2024), pp. 1–21.
- Jagadish, Akshay K, Julian Coda-Forno, Mirko Thalmann, Eric Schulz, and Marcel Binz. “Human-like Category Learning by Injecting Ecological Priors from Large Language Models into Neural Networks”. In: *arXiv* (2024), pp. 1–27.
- Ji, Jiaming et al. “AI Alignment: A Comprehensive Survey”. In: *arXiv* (2023), pp. 1–102.
- Jobe, Jared B. “Cognitive psychology and self-reports: models and methods”. In: *Quality of Life Research* 12 (2003), pp. 219–227.
- Jonas, Eric and Konrad Paul Kording. “Could a Neuroscientist Understand a Microprocessor?” In: *PLOS Computational Biology* 13.1 (2017), pp. 1–24.

- Jones, Erik and Jacob Steinhardt. “Capturing failures of large language models via human cognitive biases”. In: *Advances in Neural Information Processing Systems* 35 (2022), pp. 11785–11799.
- Kadavath, Saurav et al. “Language Models (Mostly) Know What They Know”. In: *arXiv* (2022), pp. 1–42.
- Kaplan, Jared et al. “Scaling Laws for Neural Language Models”. In: *arXiv* (2020), pp. 1–30.
- Khan, Mohammad Abdullah Matin, M. Saiful Bari, Xuan Long Do, Weishi Wang, Md Rizwan Parvez, and Shafiq Joty. “xCodeEval: A Large Scale Multilingual Multitask Benchmark for Code Understanding, Generation, Translation and Retrieval”. In: *arXiv* (2023), pp. 1–44.
- Khandelwal, Aditi, Utkarsh Agarwal, Kumar Tanmay, and Monojit Choudhury. “Do Moral Judgment and Reasoning Capability of LLMs Change with Language? A Study using the Multilingual Defining Issues Test”. In: *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics*. Association for Computational Linguistics, 2024, pp. 2882–2894.
- Kim, Geunwoo, Pierre Baldi, and Stephen McAleer. “Language Models can Solve Computer Tasks”. In: *arXiv* (2023), pp. 1–26.
- Kojima, Takeshi, Shixiang Shane Gu, Machel Reid, Yutaka Matsuo, and Yusuke Iwasawa. “Large Language Models are Zero-Shot Reasoners”. In: *arXiv* (2022), pp. 1–36.
- Kosoy, Eliza, Emily Rose Reagan, Leslie Lai, Alison Gopnik, and Danielle Krettek Cobb. “Comparing Machines and Children: Using Developmental Psychology Experiments to Assess the Strengths and Weaknesses of LaMDA Responses”. In: *NeurIPS Workshop: AI Meets Moral Philosophy and Moral Psychology*. 2023, pp. 1–11.
- Kumar, Sreejan, Theodore R Sumers, Takateru Yamakoshi, Ariel Goldstein, Uri Hasson, Kenneth A Norman, Thomas L Griffiths, Robert D Hawkins, and Samuel A Nastase. “Reconstructing the cascade of language processing in the brain using the internal computations of a transformer-based language model”. In: *BioRxiv* (2022), pp. 1–56.
- Lake, Brenden M. and Marco Baroni. “Human-like systematic generalization through a meta-learning neural network”. In: *Nature* 623 (2023), pp. 1–23.
- Lampinen, Andrew Kyle. “Can language models handle recursively nested grammatical structures? A case study on comparing models and humans”. In: *arXiv* (2022), pp. 1–22.
- Lewis, Patrick et al. “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks”. In: *Advances in Neural Information Processing Systems*. Ed. by H. Larochelle, M. Ranzato, R. Hadsell, M.F. Balcan, and H. Lin. Vol. 33. Curran Associates, Inc., 2020, pp. 9459–9474.
- Li, Changmao and Jeffrey Flanigan. “Task Contamination: Language Models May Not Be Few-Shot Anymore”. In: *arXiv* (2023), pp. 1–20.
- Li, Xingxuan, Yutong Li, Linlin Liu, Lidong Bing, and Shafiq Joty. “Is GPT-3 a Psychopath? Evaluating Large Language Models from a Psychological Perspective”. In: *arXiv* (2022), pp. 1–13.
- Linzen, Tal and Marco Baroni. “Syntactic Structure from Deep Learning”. In: *Annual Review of Linguistics* 7.1 (2021), pp. 195–212.
- Liu, Ryan, Theodore R Sumers, Ishita Dasgupta, and Thomas L Griffiths. “How do Large Language Models Navigate Conflicts between Honesty and Helpfulness?” In: *arXiv* (2024), pp. 1–21.

- Lo, Kai-Ling, Rami Ariss, and Philipp Kurz. “GPoeT-2: A GPT-2 Based Poem Generator”. In: *arXiv* (2022), pp. 1–10.
- Ma, Yecheng Jason, William Liang, Hung-Ju Wang, Sam Wang, Yuke Zhu, Linxi Fan, Osbert Bastani, and Dinesh Jayaraman. “DrEureka: Language Model Guided Sim-To-Real Transfer”. In: *Robotics: Science and Systems (RSS)*. 2024, pp. 1–28.
- Macmillan-Scott, Olivia and Mirco Musolesi. “(Ir)rationality and cognitive biases in large language models”. In: *Royal Society Open Science* 11 (2024), pp. 1–14.
- Mahowald, Kyle, Anna A Ivanova, Idan A Blank, Nancy Kanwisher, Joshua B Tenenbaum, and Evelina Fedorenko. “Dissociating language and thought in large language models”. In: *Trends in Cognitive Sciences* 28.6 (2024), pp. 517–540.
- Mazumder, Mark et al. “DataPerf: Benchmarks for Data-Centric AI Development”. In: *Advances in Neural Information Processing Systems*. Ed. by A. Oh, T. Naumann, A. Globerson, K. Saenko, M. Hardt, and S. Levine. Vol. 36. 2024, pp. 5320–5347.
- McClelland, Jay L, Mark St. John, and Roman Taraban. “Sentence comprehension: A parallel distributed processing approach”. In: *Language and Cognitive Processes* 4.3-4 (1989), SI287–SI335.
- McCoy, R Thomas, Shunyu Yao, Dan Friedman, Matthew Hardy, and Thomas L Griffiths. “Embers of Autoregression: Understanding Large Language Models Through the Problem They are Trained to Solve”. In: *arXiv* (2023), pp. 1–84.
- McCoy, Tom, Ellie Pavlick, and Tal Linzen. “Right for the Wrong Reasons: Diagnosing Syntactic Heuristics in Natural Language Inference”. In: *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*. 2019, pp. 3428–3448.
- McKenzie, Ian R. et al. “Inverse Scaling: When Bigger Isn’t Better”. In: *arXiv* (2023), pp. 1–39.
- Merrill, William, Zhaofeng Wu, Norihito Naka, Yoon Kim, and Tal Linzen. “Can You Learn Semantics Through Next-Word Prediction? The Case of Entailment”. In: *arXiv* (2024), pp. 1–22.
- Mialon, Grégoire, Roberto Dessì, Maria Lomeli, Christoforos Nalmpantis, Ram Pasunuru, and Roberta et al Raileanu. “Augmented Language Models: a Survey”. In: *arXiv* (2023), pp. 1–33.
- Miotto, Marilù, Nicola Rossberg, and Bennett Kleinberg. “Who is GPT-3? An Exploration of Personality, Values and Demographics”. In: *arXiv* (2022), pp. 1–10.
- Moghaddam, Shima Rahimi and Christopher J. Honey. “Boosting Theory-of-Mind Performance in Large Language Models via Prompting”. In: *arXiv* (2023), pp. 1–27.
- Munkhdalai, Tsendsuren, Manaal Faruqui, and Siddharth Gopal. “Leave No Context Behind: Efficient Infinite Context Transformers with Infini-attention”. In: *arXiv* (2024), pp. 1–12.
- Nair, Varun, Elliot Schumacher, Geoffrey Tso, and Anitha Kannan. “DERA: Enhancing Large Language Model Completions with Dialog-Enabled Resolving Agents”. In: *arXiv* (2023), pp. 1–38.
- Niv, Yael. *Reinforcement learning in the brain*. 2009.
- Open Science Collaboration. “Estimating the reproducibility of psychological science”. In: *Science* 349.6251 (2015), pp. 1–10.
- OpenAI. *ChatGPT: Optimizing Language Models for Dialogue*. 2022. URL: <https://openai.com/blog/chatgpt/> (visited on 02/13/2023).

- OpenAI. *GPT-4 Technical Report*. 2023. URL: <https://cdn.openai.com/papers/gpt-4.pdf> (visited on 03/19/2023).
- *GPT-4V(ision) System Card*. 2023. URL: https://cdn.openai.com/papers/GPTV_System_Card.pdf (visited on 10/13/2023).
- Oswald, Johannes von, Eyvind Niklasson, Ettore Randazzo, João Sacramento, Alexander Mordvintsev, Andrey Zhmoginov, and Max Vladymyrov. “Transformers learn in-context by gradient descent”. In: *Proceedings of the 40th International Conference on Machine Learning*. 1464. JMLR, 2023, pp. 35151–35174.
- Ouyang, Long et al. “Training language models to follow instructions with human feedback”. In: *Advances in Neural Information Processing Systems*. Ed. by S. Koyejo, S. Mohamed, A. Agarwal, D. Belgrave, K. Cho, and A. Oh. Vol. 35. 2022, pp. 27730–27744.
- Papachristou, Marios and Yuan Yuan. “Network Formation and Dynamics Among Multi-LLMs”. In: *arXiv* (2024), pp. 1–27.
- Park, Joon Sung, Lindsay Popowski, Carrie Cai, Meredith Ringel Morris, Percy Liang, and Michael S Bernstein. “Social Simulacra: Creating Populated Prototypes for Social Computing Systems”. In: *Proceedings of the 35th Annual ACM Symposium on User Interface Software and Technology*. 2022, pp. 1–18.
- Perner, Josef, Susan R. Leekam, and Heinz Wimmer. “Three-year-olds’ difficulty with false belief: The case for a conceptual deficit”. In: *The British Journal of Developmental Psychology* 5.2 (1987), pp. 125–137.
- Peterson, Joshua C., David D. Bourgin, Mayank Agrawal, Daniel Reichman, and Thomas L. Griffiths. *Using large-scale experiments and machine learning to discover theories of human decision-making*. 2021.
- Phelps, Steve and Yvan I. Russell. “The Machine Psychology of Cooperation: Can GPT models operationalise prompts for altruism, cooperation, competitiveness and selfishness in economic games?” In: *arXiv* (2024), pp. 1–38.
- Prasad, Grusha, Marten Van Schijndel, and Tal Linzen. “Using Priming to Uncover the Organization of Syntactic Representations in Neural Language Models”. In: *23rd Conference on Computational Natural Language Learning, CoNLL 2019*. 2019, pp. 66–76.
- Radford, Alec, Jong Wook Kim, Tao Xu, Greg Brockman, Christine McLeavey, and Ilya Sutskever. “Robust speech recognition via large-scale weak supervision”. In: *International Conference on Machine Learning*. 2023, pp. 28492–28518.
- Rahwan, Iyad, Manuel Cebrian, Nick Obradovich, Josh Bongard, Jean-François Bonnefon, and Cynthia et al Breazeal. “Machine behaviour”. In: *Nature* 568.7753 (2019), pp. 477–486.
- Renze, Matthew and Erhan Guven. “The Effect of Sampling Temperature on Problem Solving in Large Language Models”. In: *arXiv* (2024).
- Röttger, Paul, Valentin Hofmann, Valentina Pyatkin, Musashi Hinck, Hannah Rose Kirk, Hinrich Schütze, and Dirk Hovy. “Political Compass or Spinning Arrow? Towards More Meaningful Evaluations for Values and Opinions in Large Language Models”. In: *arXiv* (2024), pp. 1–17.
- Ruis, Laura, Jacob Andreas, and Brenden M. Lake. “Improving Systematic Generalization Through Modularity and Augmentation”. In: *arXiv* (2022), pp. 1–9.
- Ruis, Laura Eline, Akbir Khan, Stella Biderman, Sara Hooker, Tim Rocktäschel, and Edward Grefenstette. “The Goldilocks of Pragmatic Understanding: Fine-Tuning Strategy Matters for Implicature Resolution by LLMs”.

- In: *Advances in Neural Information Processing Systems*. Ed. by A. Oh, T. Naumann, A. Globerson, K. Saenko, M. Hardt, and S. Levine. Vol. 36. 2023, pp. 20827–20905.
- Russakovsky, Olga et al. “ImageNet Large Scale Visual Recognition Challenge”. In: *International Journal of Computer Vision* 115 (2015), pp. 211–252.
- Ryle, Gilbert. *Collected Papers*. Hutchinson, 1971.
- Salewski, Leonard, Stephan Alaniz, Isabel Rio-Torto, Eric Schulz, and Zeynep Akata. “In-Context Impersonation Reveals Large Language Models’ Strengths and Biases”. In: *arXiv* (2023), pp. 1–27.
- Sap, Maarten, Ronan Le Bras, Daniel Fried, and Yejin Choi. “Neural Theory-of-Mind? On the Limits of Social Intelligence in Large LMs”. In: *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*. Ed. by Yoav Goldberg, Zornitsa Kozareva, and Yue Zhang. Association for Computational Linguistics, 2022, pp. 3762–3780.
- Scarpina, Federica and Sofia Tagini. “The Stroop Color and Word Test”. In: *Frontiers in Psychology* 8 (2017), pp. 1–8.
- Schaeffer, Rylan, Brando Miranda, and Sanmi Koyejo. “Are Emergent Abilities of Large Language Models a Mirage?” In: *Proceedings of the 37th International Conference on Neural Information Processing Systems*. 2425. Curran Associates Inc., 2023, pp. 1–17.
- Schick, Timo, Jane Dwivedi-Yu, Roberto Dessì, Roberta Raileanu, Maria Lomeli, Luke Zettlemoyer, Nicola Cancedda, and Thomas Scialom. “Toolformer: Language Models Can Teach Themselves to Use Tools”. In: *arXiv* (2023), pp. 1–17.
- Schramowski, Patrick, Cigdem Turan, Nico Andersen, Constantin A Rothkopf, and Kristian Kersting. “Large pre-trained language models contain human-like biases of what is right and wrong to do”. In: *Nature Machine Intelligence* 4.3 (2022), pp. 258–268.
- Schubert, Johannes A, Akshay K Jagadish, Marcel Binz, and Eric Schulz. “In-context learning agents are asymmetric belief updaters”. In: *arXiv* (2024), pp. 1–16.
- Schulze Buschoff, Luca M, Elif Akata, Matthias Bethge, and Eric Schulz. “Visual cognition in multimodal large language models”. In: *arXiv* (2023), pp. 1–18.
- Schwartz, Matthew D. “Should artificial intelligence be interpretable to humans?” In: *Nature Reviews Physics* 4.12 (2022), pp. 741–742.
- Seals, S. M. and Valerie L. Shalin. “Long-form analogies generated by chatGPT lack human-like psycholinguistic properties”. In: *arXiv* (2023), pp. 1–8.
- Searle, John R. “Minds, brains, and programs”. In: *Behavioral and Brain Sciences* 568.7753 (1980), pp. 417–424.
- Sellars, Wilfrid. *Empiricism and the Philosophy of Mind*. Harvard University Press, 1997.
- Shanahan, Murray. “Talking About Large Language Models”. In: *arXiv* (2022), pp. 1–11.
- Shanahan, Murray, Kyle McDonell, and Laria Reynolds. “Role play with large language models”. In: *Nature* 623.7987 (2023), pp. 493–498.
- Shevlin, Henry and Marta Halina. “Apply rich psychological terms in AI with care”. In: *Nature Machine Intelligence* 1 (2019), pp. 165–167.

- Sinclair, Arabella, Jaap Jumelet, Willem Zuidema, and Raquel Fernández. “Structural Persistence in Language Models: Priming as a Window into Abstract Language Representations”. In: *Transactions of the Association for Computational Linguistics* 10 (2022), pp. 1031–1050.
- Singla, Sahil and Soheil Feizi. “Causal ImageNet: How to discover spurious features in Deep Learning?” In: *arXiv* (2021), pp. 1–76.
- Srivastava, Aarohi et al. “Beyond the Imitation Game: Quantifying and extrapolating the capabilities of language models”. In: *arXiv* (2022), pp. 1–100.
- Stevenson, Claire, Iris Smal, Matthijs Baas, Raoul Grasman, and Han van der Maas. “Putting GPT-3’s Creativity to the (Alternative Uses) Test”. In: *arXiv* (2022), pp. 1–5.
- Stolfo, Alessandro, Yonatan Belinkov, and Mrinmaya Sachan. “A Mechanistic Interpretation of Arithmetic Reasoning in Language Models using Causal Mediation Analysis”. In: *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. 2023, pp. 7035–7052.
- Strachan, James W. A. et al. “Testing theory of mind in large language models and humans”. In: *Nature Human Behaviour* 8 (2024), pp. 1285–1295.
- Street, Winnie et al. “LLMs achieve adult human performance on higher-order theory of mind tasks”. In: *arXiv* (2024), pp. 1–18.
- Todd, Peter M and Gerd Gigerenzer. *Ecological Rationality: Intelligence in the World*. Oxford University Press, 2012.
- Tsvilodub, Polina, Hening Wang, Sharon Grosch, and Michael Franke. “Predictions from language models for multiple-choice tasks are not robust under variation of scoring methods”. In: *arXiv* (2024), pp. 1–8.
- Tversky, Amos and Daniel Kahneman. “Judgment under Uncertainty: Heuristics and Biases”. In: *Science* 185.4157 (1974), pp. 1124–1131.
- “The Framing of Decisions and the Psychology of Choice”. In: *Science* 211.4481 (1981), pp. 453–458.
- Ullman, Tomer. “Large Language Models Fail on Trivial Alterations to Theory-of-Mind Tasks”. In: *arXiv* (2023), pp. 1–11.
- Vrieze, Scott I. “Model selection and psychological theory: a discussion of the differences between the Akaike information criterion (AIC) and the Bayesian information criterion (BIC)”. In: *Psychological Methods* 17.2 (2012), pp. 228–243.
- Wang, Kevin, Alexandre Variengien, Arthur Conmy, Buck Shlegeris, and Jacob Steinhardt. “Interpretability in the Wild: a Circuit for Indirect Object Identification in GPT-2 small”. In: *arXiv* (2022), pp. 1–25.
- Wang, Xuezhi, Jason Wei, Dale Schuurmans, Quoc Le, Ed Chi, Sharan Narang, Aakanksha Chowdhery, and Denny Zhou. “Self-Consistency Improves Chain of Thought Reasoning in Language Models”. In: *arXiv* (2022), pp. 1–24.
- Warstadt, Alex et al. “Findings of the BabyLM Challenge: Sample-Efficient Pretraining on Developmentally Plausible Corpora”. In: *Proceedings of the BabyLM Challenge at the 27th Conference on Computational Natural Language Learning*. Ed. by Alex Warstadt et al. Association for Computational Linguistics, 2023, pp. 1–34.
- Webb, Taylor, Keith J Holyoak, and Hongjing Lu. “Emergent analogical reasoning in large language models”. In: *Nature Human Behaviour* 7.9 (2023), pp. 1526–1541.

- Wei, Jason, Yi Tay, et al. “Emergent Abilities of Large Language Models”. In: *Transactions on Machine Learning Research* (2022), pp. 1–30.
- Wei, Jason, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Brian Ichter, Fei Xia, Ed Chi, Le Quoc, and Denny Zhou. “Chain of Thought Prompting Elicits Reasoning in Large Language Models”. In: *arXiv* (2022), pp. 1–41.
- Weidinger, Laura, Jonathan Uesato, Maribeth Rauh, Conor Griffin, Po-Sen Huang, and John et al Mellor. “Taxonomy of Risks posed by Language Models”. In: *Proceedings of the 2022 ACM Conference on Fairness, Accountability, and Transparency*. Association for Computing Machinery, 2022, pp. 214–229.
- Wilcox, Ethan Gotlieb, Richard Futrell, and Roger Levy. “Using Computational Models to Test Syntactic Learnability”. In: *Linguistic Inquiry* (2023), pp. 1–44.
- Wimmer, H. and J Perner. “Beliefs about beliefs: representation and constraining function of wrong beliefs in young children’s understanding of deception”. In: *Cognition* 13.1 (1983), pp. 103–128.
- Xie, Sang Michael, Aditi Raghunathan, Percy Liang, and Tengyu Ma. “An Explanation of In-context Learning as Implicit Bayesian Inference”. In: *International Conference on Learning Representations*. 2022, pp. 1–25.
- Yang, Yuhong. “COMPARING LEARNING METHODS FOR CLASSIFICATION”. In: *Statistica Sinica* 2 (2006), pp. 635–657.
- Yarkoni, Tal. “The generalizability crisis”. In: *Behavioral and Brain Sciences* 45 (2022), pp. 1–37.
- Yax, Nicolas, Hernan Anlló, and Stefano Palminteri. “Studying and improving reasoning in humans and machines”. In: *Communications Psychology* 2.1 (2024), pp. 1–16.
- Yiu, Eunice, Eliza Kosoy, and Alison Gopnik. “Transmission Versus Truth, Imitation Versus Innovation: What Children Can Do That Large Language and Language-and-Vision Models Cannot (Yet)”. In: *Perspectives on Psychological Science* 0.0 (2023), pp. 1–10.
- Zellers, Rowan, Ari Holtzman, Yonatan Bisk, Ali Farhadi, and Yejin Choi. “HellaSwag: Can a Machine Really Finish Your Sentence?”. In: *Annual Meeting of the Association for Computational Linguistics*. 2019, pp. 1–10.
- Zhang, Jingyi, Jiaxing Huang, Sheng Jin, and Shijian Lu. “Vision-Language Models for Vision Tasks: A Survey”. In: *arXiv* (2024), pp. 1–24.
- Zhang, Tianhua, Jiaxin Ge, et al. “Natural Language Embedded Programs for Hybrid Language Symbolic Reasoning”. In: *Findings of the Association for Computational Linguistics: NAACL 2024*. Ed. by Kevin Duh, Helena Gomez, and Steven Bethard. 2024, pp. 4131–4155.
- Zhao, Haiyan, Hanjie Chen, F. Yang, Ninghao Liu, Huiqi Deng, Hengyi Cai, Shuaiqiang Wang, Dawei Yin, and Mengnan Du. “Explainability for Large Language Models: A Survey”. In: *ACM Transactions on Intelligent Systems and Technology* 15 (2023), pp. 1–38.
- Zhao, Tony Z., Eric Wallace, Shi Feng, Dan Klein, and Sameer Singh. “Calibrate Before Use: Improving Few-Shot Performance of Language Models”. In: *arXiv* (2021), pp. 1–15.
- Zheng, Xiaosen, Tianyu Pang, Chao Du, Qian Liu, Jing Jiang, and Min Lin. “Improved Few-Shot Jailbreaking Can Circumvent Aligned Language Models and Their Defenses”. In: *arXiv* (2024), pp. 1–22.
- Zhou, Denny, Nathanael Schärli, Le Hou, Jason Wei, Nathan Scales, and Xuezhi et al Wang. “Least-to-Most Prompting Enables Complex Reasoning in Large Language Models”. In: *arXiv* (2022), pp. 1–63.